

Статистическое исследование. Случайные величины и их характеристики

1. Основные термины. Статистическое исследование
2. Дискретные случайные величины
3. Характеристики дискретных случайных величин
4. Интервальный ряд распределения
5. Графическое изображение рядов распределения

1.1 Основные термины

*Статистика*¹ – это:

- 1) массивы эмпирических данных по какому-нибудь предмету;
- 2) практическая деятельность по сбору, анализу, интерпретации, представлению и организации статистических данных;
- 3) наука, которая разрабатывает конкретные методы оценки параметров массовых явлений, тенденций их развития или гипотез о наличии взаимосвязей между ними на основе фактов.

*Данные*² – это информация, обработанная и представленная в формализованном виде для дальнейшей обработки.

*Информация*³ – сведения (сообщения, данные) независимо от формы их представления.

¹ Большая российская энциклопедия

² ГОСТ 7.0-99 Информационно-библиотечная деятельность, библиография

³ ФЗ от 27.07.2006 N 149-ФЗ «Об информации, информационных технологиях и о защите информации»

Статистическая совокупность – множество элементов, объединенных по определенному критерию, но отличающихся по отдельным признакам.

Единица совокупности – первичный элемент статистической совокупности, являющийся носителем признаков, подлежащих регистрации.

Признак – особенность единицы совокупности. Признаки разделяются на *количественные*, которые могут быть представлены в виде чисел (возраст, доход) и *качественные (атрибутивные)*, не имеющие численного представления (цвет).

Вариация – различия значений количественного признака у единиц совокупности. Интерес представляют только варьирующиеся признаки.

Статистический показатель – характеристика признака, имеющая количественное выражение (средний доход).

Статистические данные – количественные значения признаков или статистических показателей (средний доход равен 80 тыс. руб.).

1.2 Этапы статистического исследования

1. *Статистическое наблюдение*, заключающееся в сборе первичной статистической информации и ее регистрации.

2. *Систематизация* первичной информации, её декомпозиция на группы и подгруппы по отдельным признакам (*группировка*).

3. *Анализ статистических данных*, в ходе которого вычисляются характеристические показатели и строятся модели, что позволяет выявить структуру, динамику, взаимосвязи и закономерности развития процессов.

*Основным постулатом является **закон больших чисел**⁴: совместное действие большого числа случайных факторов приводит при некоторых весьма общих условиях к результату, почти не зависящему от случая.*

4. *Прогнозирование*, служащее основой для принятия решений.

⁴ Большая российская энциклопедия

2. Случайной называют величину, которая в результате испытания примет одно и только одно возможное значение, наперед не известное и зависящее от случайных причин, которые заранее не могут быть учтены.

Дискретной называют случайную величину, принимающую отдельные, изолированные возможные значения с определенными вероятностями.

Непрерывной называют случайную величину, которая может принимать все значения из некоторого промежутка.

Число возможных значений дискретной случайной величины конечно или бесконечно? А непрерывной?

Закон распределения дискретной случайной величины – это соответствие между возможными значениями и их вероятностями, представленное в виде теоретического ряда распределения.

X	x_1	x_2	$\dots$	x_k
P	p_1	p_2	$\dots$	p_k

Статистический ряд распределения – группировка статистической совокупности по определенному признаку, которая фиксирует соответствие между значением признака и количеством единиц с этим признаком.

Значения количественных признаков называются *вариантами*, количество единиц каждого признака – *частотой*.

Варианты, расположенные в порядке возрастания, образуют *вариационный ряд*.

x_i (варианта)	x_1	x_2	...	x_k
n_i (частота)	n_1	n_2	...	n_k
w_i (относительная частота)	$\frac{n_1}{N}$	$\frac{n_2}{N}$	...	$\frac{n_k}{N}$

N – сумма частот: $N = \sum_{i=1}^k n_i$

При неограниченном увеличении числа испытаний относительная частота w_i появления варианты x_i сходится по вероятности к p_i ($i = 1, \dots, k$).

$$\lim_{k \rightarrow \infty} P\{|w_i - p_i| < \varepsilon\} = 1, \quad \forall \varepsilon > 0$$

3.1 Теоретические характеристики дискретной случайной величины

1. *Математическое ожидание* – сумма произведений всех возможных значений случайной величины на их вероятности.

$$M(X) = \sum_{i=1}^k x_i \cdot p_i \quad (3.1)$$

2. *Дисперсия* – математическое ожидание квадрата отклонения случайной величины от ее математического ожидания:

$$D(X) = M[X - M(X)]^2 = \sum_{i=1}^k (x_i - M(X))^2 \cdot p_i \quad (3.2)$$

или
$$D(X) = M(X^2) - [M(X)]^2$$

3. *Среднее квадратическое отклонение (стандарт)* случайной величины – квадратный корень из дисперсии:

$$\sigma(X) = \sqrt{D(X)} \quad (3.3)$$

4. *Мода* – максимально вероятное значение случайной величины:

$$Mo = x_i: \quad p(x_i) = \max_i \{p_i\} \quad (3.4)$$

5. *Медиана* – значение случайной величины, соответствующее середине упорядоченного по величине ряда значений переменной:

$$Me = z: \quad \sum_{x_i \leq z} p(x_i) = 0,5 \quad (3.5)$$

Если общее число k значений случайной величины нечетно, то есть $k = 2m + 1$, медиана равна срединному значению: $Me = x_{m+1}$. При четном k ($k = 2m$), медианой является среднее арифметическое двух срединных значений: $Me = \frac{x_m + x_{m+1}}{2}$.

6. *Размах* – разность между наибольшим и наименьшим значением:

$$R = x_{max} - x_{min} \quad (3.6)$$

7. *Коэффициент вариации* – относительная характеристика рассеивания:

$$V(X) = \frac{\sigma(X)}{M(X)} \quad (3.7)$$

3.2 Статистические характеристики случайной величины

1. *Выборочная средняя (средняя)* – среднее арифметическое значений случайной величины (N – сумма частот):

$$\bar{x} = \frac{1}{N} \sum_{i=1}^k x_i \cdot n_i \quad (3.8)$$

2. *Отклонениями* называется совокупность значений

$$x_1 - \bar{x}, \quad x_2 - \bar{x}, \dots, x_k - \bar{x} \quad (3.9)$$

3. *Дисперсия* – мера рассеивания значений относительно средней:

$$D(X) = \frac{1}{N} \sum_{i=1}^k (x_i - \bar{x})^2 \cdot n_i \quad (3.10)$$

$$D(X) = \overline{x^2} - (\bar{x})^2 = \frac{1}{N} \sum_{i=1}^k x_i^2 \cdot n_i - \left(\frac{1}{N} \sum_{i=1}^k x_i \cdot n_i \right)^2 \quad (3.10')$$

4. *Среднее квадратическое отклонение:*

$$\sigma(X) = \sqrt{D(X)} \quad (3.11)$$

5. *Модой M_o* называется варианта с наибольшей частотой, то есть значение случайной величины, наблюдаемое чаще всего.

6. *Медиана Me* – величина, которая делит вариационный ряд на две равные части. Если число вариантов нечетное ($k = 2m + 1$), то $Me = x_{m+1}$. Если число вариантов четное ($k = 2m$), то $Me = \frac{x_m + x_{m+1}}{2}$.

7. *Размах* – разность между наибольшей и наименьшей вариантами:

$$R = x_{max} - x_{min} \quad (3.12)$$

8. *Коэффициент вариации* – выраженное в процентах отношение среднего квадратического отклонения к средней:

$$V(X) = \frac{\sigma(X)}{\bar{x}} \cdot 100\% \quad (3.13)$$

Совокупность называется *однородной* по определенному признаку, если количественные значения этого признака незначительно варьируются относительно средней.

Если исследуемая совокупность имеет значительную вариацию определенного признака, то она считается *неоднородной*.

Чем больше коэффициент вариации, тем менее однородна совокупность, и тем хуже средняя характеризует изучаемый признак. Имеет смысл усреднять показатели совокупности, если $V(X) < 33,3\%$.

В противном случае совокупность неоднородна, и применение средней для обобщения показателей совокупности нецелесообразно.

Статистическая совокупность может быть однородной по одному признаку, и неоднородной – по другому.

Пример 3.1 Для определения температуры плавления припоя проведено 9 контрольных измерений, в результате которых получены значения (градусы Цельсия):

168 176 180
180 174 176
182 174 176

Построить статистический ряд распределения и вычислить статистические характеристики.

Решение. Статистический ряд распределения:

Значения температуры (x_i)	168	174	176	180	182
Частота (n_i)	1	2	3	2	1

1) *Средняя:*

$$\bar{x} = \frac{168 \cdot 1 + 174 \cdot 2 + 176 \cdot 3 + 180 \cdot 2 + 182 \cdot 1}{9} = \frac{1586}{9} = 176,22 \approx 176$$

2) *Отклонения:* $168 - 176 = -8$, $174 - 176 = -2$, $176 - 176 = 0$,
 $180 - 176 = 4$, $182 - 176 = 6$.

3) *Дисперсия:*

$$D(X) = \frac{(-8)^2 \cdot 1 + (-2)^2 \cdot 2 + 0 \cdot 3 + 4^2 \cdot 2 + 6^2 \cdot 1}{9} = \frac{64 + 8 + 0 + 32 + 36}{9} = \frac{140}{9} \approx 16$$

4) *Среднее квадратическое отклонение:* $\sigma(X) = \sqrt{D(X)} = \sqrt{16} = 4$.

5) *Мода:* $M_o = 176$ с частотой 3. 6) *Медиана:* $M_e = 176$.

7) *Размах:* $R = 182 - 168 = 14$

8) *Коэффициент вариации:* $V(X) = \frac{\sigma(X)}{\bar{x}} \cdot 100\% = \frac{4}{176} \cdot 100\% = 2,27\%$.




Рисунок 2.1 – Колебания температуры

Пример 3.2 В таблице дано распределение ежемесячного дохода работников предприятия. Найти статистические характеристики.

Доход, тыс. руб.	20	50	80	200
Частота	12	4	3	1

4. Интервальные ряды распределения

Интервальный ряд распределения – это вид статистического ряда распределения, в котором варианты заданы в виде интервала.

Для вычисления *средней* интервального ряда сначала надо найти середину каждого интервала (полусумма левой и правой границы), а затем среднюю для всего ряда:

$$\bar{x} = \frac{1}{N} \sum_{i=1}^k \frac{x_i^l + x_i^r}{2} \cdot n_i = \frac{1}{N} \sum_{i=1}^k x_i' \cdot n_i \quad (4.1)$$

N – сумма всех частот, x_i^l и x_i^r – соответственно левая и правая границы i -го интервала, x_i' – середина i -го интервала

При расчете *дисперсии* также используются средние интервалов:

$$D(X) = \frac{1}{N} \sum_{i=1}^k (x_i' - \bar{x})^2 \cdot n_i \quad (4.2)$$

Для вычисления *моды* выбирается интервал, имеющий наибольшую частоту (*модальный интервал*), затем применяется формула:

$$Mo = x_i^l + h \cdot \frac{n_i - n_{i-1}}{(n_i - n_{i-1}) + (n_i - n_{i+1})} \quad (4.3)$$

x_i^l – левая граница модального интервала, h – длина модального интервала, n_i – частота модального интервала, n_{i-1} – частота интервала, предшествующего модальному, n_{i+1} – частота интервала, следующего за модальным.

Для расчета *медианы* сначала находится *медианный интервал*, накопленная частота которого превышает половину общей суммы частот, после этого вычисления проводятся по формуле (3.10):

$$Me = x_i^l + h \cdot \frac{\frac{N}{2} - S_{i-1}}{n_i} \quad (4.4)$$

x_i^l – левая граница медианного интервала, h – длина медианного интервала, N – сумма всех частот, S_{i-1} – сумма накопленных частот интервала, предшествующего медианному, n_i – частота медианного интервала.

Пример 4.1 Вычислить характеристики совокупности преступлений, совершаемых в банках, по признаку «сумма активов».

Сумма активов, млн. руб.	Количество преступлений
До 300	24
300-500	21
500-700	15
700-900	32
900 и более	14
Всего	106

Дополним таблицу вспомогательными расчетами.

Сумма активов, млн. руб., x_i	До 300	300-500	500-700	700-900	900 и более
Середина интервала, x'_i	200	400	600	800	1000
Число преступлений (частота), n_i	24	21	15	32	14
Накопленные частоты, S_i	24	45	60	92	106

1. *Средняя*:

$$\bar{x} = \frac{200 \cdot 24 + 400 \cdot 21 + 600 \cdot 15 + 800 \cdot 32 + 1000 \cdot 14}{106} = 583 \text{ (млн. руб.)}$$

2. *Отклонения* от средней: $200 - 583 = -383$; $400 - 583 = -183$,
 $600 - 583 = 17$, $800 - 583 = 217$, $1000 - 583 = 417$.

3. *Дисперсия*:

$$D(X) = \frac{(-383)^2 \cdot 24 + (-183)^2 \cdot 21 + 17^2 \cdot 15 + 217^2 \cdot 32 + 417^2 \cdot 14}{106} =$$
$$= 77070 \text{ (млн. руб.)}^2$$

4. *СКО*: $\sigma(X) = \sqrt{77070} \approx 277,6 \text{ (млн. руб.)}$

5. *Мода*. Модальным является интервал 700-900 млн. руб. Левая граница $x_4^l = 700$ ($i = 4$), длина $h = 200$, частота $n_4 = 32$, $n_3 = 15$, $n_5 = 14$.

$$Mo = 700 + 200 \cdot \frac{32 - 15}{(32 - 15) + (32 - 14)} = 797,1 \text{ (млн. руб.)}$$

6. *Медиана*. Общая сумма частот – 106, значит, половина накопленных частот равна 53. Первое значение накопленных частот $S_3 = 60 > 53$ соответствует интервалу 500-700 млн. руб., поэтому он и будет являться медианным ($i = 3$). Левая граница $x_3^l = 500$, длина $h = 200$, частота $n_3 = 15$, сумма накопленных частот предыдущего интервала $S_2 = 45$.

$$Me = 500 + 200 \cdot \frac{\frac{106}{2} - 45}{15} = 606,7 \text{ (млн. руб.)}$$

7. Для определения *размаха* нужно найти наименьшую и наибольшую варианты, то есть левую границу первого интервала и правую границу последнего интервала. Если границы не заданы, длина неизвестного крайнего интервала принимается равной длине соседнего.

В данном ряду длина всех интервалов $h = 200$, поэтому

$$x_{max} = 900 + 200 = 1100, \quad x_{min} = 300 - 200 = 100$$

$$R = 1100 - 100 = 1000 \text{ (млн. руб.)}$$

8. *Коэффициент вариации*: $V(X) = \frac{277,6}{583} \cdot 100\% = 47,6\%$

5. Графическое изображение рядов распределения

Для наглядного изображения рядов распределения используются статистические графики: *полигон частот* (для дискретных рядов) и *гистограмма частот* (для интервальных рядов).

Полигон частот – это график в прямоугольной системе координат, на горизонтальной оси которого откладывают значения признака, а на вертикальной – соответствующие частоты. Точки соединяются отрезками, образуя ломаную линию (рисунок 5.1).

Гистограмма частот строится в прямоугольной системе координат. На горизонтальной оси откладывают интервалы признака. На отрезках, образованных границами интервалов, строят прямоугольники с высотой, равной соответствующей частоте (рисунок 5.2).

Пример 5.1 Построить полигон частот для ряда распределения:

Варианта, x_i	2	3	5	7	11
Частота, n_i	3	8	7	4	5




Рисунок 5.1 – Полигон частот дискретного ряда распределения

Пример 5.2 Построить гистограмму частот для ряда распределения:

Варианта x_i	0-2	2-4	4-6	6-8	8-10
Частота n_i	3	8	7	4	5




Рисунок 5.2 – Гистограмма частот интервального ряда распределения