Статистические оценки параметров распределения. Ч.1.

1. Особенности выборочного наблюдения
2. Задача оценивания параметров распределения
3. Методы нахождения точечных оценок
4. Выравнивание статистических рядов

1.1 Виды статистического наблюдения

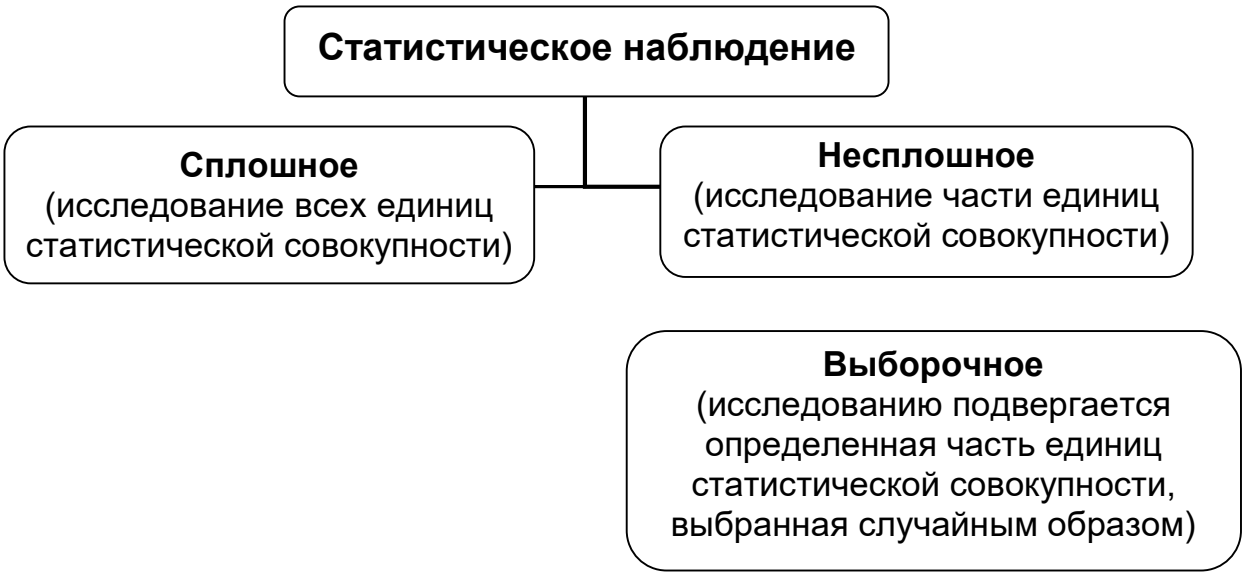


Рисунок 1.1 – Виды статистического наблюдения

1.2 Генеральная и выборочная совокупность

Генеральной называют совокупность всех исследуемых объектов.

Выборочной совокупностью (выборкой) называют совокупность единиц, отобранных для исследования.

Объемом совокупности (выборочной или генеральной) называется число объектов этой совокупности.

Выборка называется *повторной*, если отобранные единицы после обследования возвращаются в генеральную совокупность и снова могут попасть в выборку, или *бесповторной*, если отобранные единицы после обследования в генеральную совокупность не возвращаются.

Репрезентативность – свойство выборки объективно отображать характеристики генеральной совокупности.

Условия репрезентативности выборки:

- отбор объектов осуществляется случайным образом;
- объем выборки достаточно велик для обеспечения заданной точности.

1.3 Определение объема выборки

Объем выборки, при которой ошибка не превысит заданную точность δ, рассчитывается по формулам:

1) *для повторной выборки*

$$n = \frac{t^2\sigma^2}{\delta^2} \tag{1.1}$$

2) *для бесповторной выборки*

$$n = \frac{Nt^2\sigma^2}{N\delta^2 + t^2\sigma^2} \tag{1.2}$$

σ – среднее квадратическое отклонение, δ – точность,

n – объем выборки, *N* – объем генеральной совокупности,

t – коэффициент кратности ошибки, определяемый по таблице значений функции Лапласа: $2\Phi(t) = \gamma$ ($\Phi(t) = \gamma/2$),

γ – надежность (доверительная вероятность).

2.1 Задача оценивания параметров распределения

Постановка задачи: по данным выборки $x_1, x_2, \dots, x_n$, полученным в результате n независимых наблюдений, найти *статистическую оценку* неизвестного параметра теоретического распределения – функцию от наблюдаемых случайных величин $\hat{\Theta}(x_1, x_2, \dots, x_n)$.

Несмещенной называется статистическая оценка $\hat{\Theta}$, математическое ожидание которой равно оцениваемому параметру Θ при любом объеме выборки: $M(\hat{\Theta}) = \Theta$. В противном случае оценка называется *смещенной.*

Эффективной называется статистическая оценка, которая при заданном объеме выборки n имеет наименьшую возможную дисперсию.

Состоятельной называется статистическая оценка, которая при $n \to \infty$ стремится по вероятности к оцениваемому параметру:

$$\lim_{n\to\infty} P\{|\hat{\Theta} - \Theta| < \varepsilon\} = 1, \qquad \forall \varepsilon > 0 \tag{2.1}$$

Если дисперсия несмещенной оценки при $n \to \infty$ стремится к нулю, то такая оценка оказывается и состоятельной.

2.2 Точность и доверительная вероятность оценки

Точечной называется оценка, определяемая одним числом.

Интервальной называется оценка, определяемая концами интервала.

Пусть найденная по данным выборки статистическая характеристика $\hat{\Theta}$ служит оценкой неизвестного параметра Θ. Оценка $\hat{\Theta}$ тем точнее определяет параметр Θ, чем меньше разность $\left|\hat{\Theta} - \Theta\right|$.

Точность оценки характеризуется числом $\delta > 0$:

$$\left|\hat{\Theta} - \Theta\right| < \delta \tag{2.2}$$

Надежностью (доверительной вероятностью) оценки называется вероятность γ, с которой выполняется неравенство (2.2):

$$P\left(\hat{\Theta} - \delta < \Theta < \hat{\Theta} + \delta\right) = \gamma \tag{2.3}$$

Выражение (2.3) определяет вероятность того, что интервал $\left(\hat{\Theta} - \delta,\ \hat{\Theta} + \delta\right)$ заключает в себе (покрывает) неизвестный параметр Θ.

Доверительным называется интервал $\left(\hat{\Theta} - \delta,\ \hat{\Theta} + \delta\right)$, который покрывает неизвестный параметр с заданной надежностью γ.

Обычно надежность оценки задается наперед, числом, близким к единице. Наиболее часто задают надежность 0,95; 0,99 и 0,999.

Доверительный интервал имеет случайные концы (доверительные границы). В разных выборках получаются различные значения $\hat{\Theta}$, следовательно, от выборки к выборке будут изменяться и концы доверительного интервала, то есть доверительные границы являются случайными величинами – функциями от $x_1, x_2,\ldots, x_n$.

Так как случайной величиной является не оцениваемый параметр Θ, а доверительный интервал, то правильнее говорить не о вероятности попадания Θ в доверительный интервал, а о вероятности того, что доверительный интервал покроет Θ.

3.1 Метод моментов заключается в приравнивании теоретических моментов соответствующим эмпирическим моментам того же порядка.

1) Для оценки одного параметра начальный теоретический момент первого порядка $M(X)$ полагается равным начальному эмпирическому моменту первого порядка $\bar{x}$:

$$M(X) = \bar{x} \tag{3.1}$$

2) Для оценки двух параметров начальный теоретический момент первого порядка полагается равным начальному эмпирическому моменту первого порядка и центральный теоретический момент второго порядка – центральному эмпирическому моменту второго порядка:

$$\begin{cases} M(X) = \bar{x} \\ D(X) = D^*(X) \end{cases} \tag{3.2}$$

Пример 3.1 Случайная величина X (время безотказной работы элемента) имеет показательное распределение. Ниже приведено эмпирическое распределение среднего времени работы 1000 элементов (среднее время x_i безотказной работы одного элемента в часах и частота n_i, то есть количество элементов, проработавших в среднем x_i часов). Найти методом моментов точечную оценку неизвестного параметра.

x_i	5	15	25	35	45	55	65
n_i	365	245	150	100	70	45	25

Решение. Плотность показательного распределения равна

$$f(x) = \lambda e^{-\lambda x} \ (x \geq 0)$$

Приравняем моменты первого порядка: $M(X) = \bar{x}$

Математическое ожидание показательного распределения $M(X) = 1/\lambda$

$$\bar{x} = \frac{1}{\lambda} \Longrightarrow \lambda = \frac{1}{\bar{x}} = \frac{1}{20} = 0{,}05$$

Ответ: $1/20$.

3.2 Метод максимального правдоподобия

Пусть каждому элементу выборки $x_1, x_2 \ldots, x_n$ ставится в соответствие плотность распределения $f(x_i, \Theta)$, определяемая неизвестным параметром Θ.

Функцией правдоподобия называется функция

$$L(x_1, x_2, \ldots, x_n, \Theta) = f(x_1, \Theta) \cdot f(x_2, \Theta) \cdot \ldots \cdot f(x_n, \Theta) \qquad (3.3)$$

В качестве точечной оценки параметра Θ принимают такое его значение $\hat{\Theta}$, при котором функция правдоподобия достигает максимума.

Оценку $\hat{\Theta}$ называют *оценкой наибольшего правдоподобия*.

Функции L и $\ln L$ достигают максимума при одном и том же значении Θ, поэтому вместо поиска максимума функции L ищут максимум функции $\ln L$, называемой *логарифмической функцией правдоподобия*.

Для определения точки максимума производная $\frac{d \ln L}{d\Theta}$ приравнивается к нулю. Корень уравнения – критическая точка, является максимумом, если вторая производная отрицательна при $\Theta = \hat{\Theta}$.

Пример 3.2 Найти методом максимального правдоподобия точечную оценку неизвестного параметра из предыдущего примера.

Решение. Функция правдоподобия имеет вид

$$L = \left(\lambda e^{-\lambda x_1}\right) \cdot \left(\lambda e^{-\lambda x_2}\right) \ldots \left(\lambda e^{-\lambda x_n}\right) = \lambda^n e^{-\lambda \sum x_i}$$

$$\ln L = n \ln \lambda - \lambda \sum_{i=1}^{n} x_i$$

$$\frac{\partial \ln L}{\partial \lambda} = \frac{n}{\lambda} - \sum_{i=1}^{n} x_i = 0$$

$$\frac{n}{\lambda} = \sum_{i=1}^{n} x_i \implies \lambda = \frac{n}{\sum x_i} = \frac{1}{\bar{x}} = \frac{1}{20}$$

$$\frac{\partial^2 \ln L}{\partial \lambda^2} = -\frac{n}{\lambda^2} < 0 \implies \lambda - \text{точка максимума}$$

Ответ: $1/20$.

4. Выравнивание статистических рядов

При обработке статистических данных приходится решать вопрос о том, как подобрать для данного статистического ряда теоретическую кривую распределения, выражающую основные черты исследуемого явления, но не случайности, связанные с недостаточным объемом экспериментальных данных. Такая задача называется *задачей выравнивания (сглаживания) статистических рядов*.

Как правило, принципиальный вид теоретической кривой выбирается из соображений, связанных природой решаемой задачи, а в некоторых случаях исходя из визуального представления статистического распределения.

Если величина X – ошибка измерения, возникающая в результате суммирования воздействий множества независимых элементарных ошибок, тогда из теоретических соображений можно считать, что величина X подчиняется нормальному закону, и задача выравнивания сводится к задаче о рациональном выборе параметров распределения.

Предположим, что, исходя из тех или иных соображений, для выравнивания статистического ряда выбрана функция *f*(*x*), удовлетворяющая условиям:

$$\begin{cases} f(x) \geq 0 \\ \int_{-\infty}^{\infty} f(x)dx = 1 \end{cases}$$

В выражение этой функции входит несколько параметров, которые нужно подобрать так, чтобы функция $f(x)$ наилучшим образом описывала исходные статистические данные.

Для решения этой задачи находятся точечные оценки параметров распределения.

Пример 4.1 Произведено 500 измерений боковой ошибки наводки при стрельбе с самолета по наземной цели. Результаты измерений (в тысячных долях радиана) сведены в статистический ряд. Выровнять распределение с помощью нормального закона.

x_i	–4; –3	–3; –2	–2; –1	–1; 0	0; 1	1; 2	2; 3	3; 4
$w_i\,(p_i^*)$	0,012	0,05	0,144	0,266	0,24	0,176	0,092	0,02

Найдем оценки параметров a и σ методом моментов.

$$a = \overline{x} = \sum_{i=1}^{k} x_i \cdot w_i$$

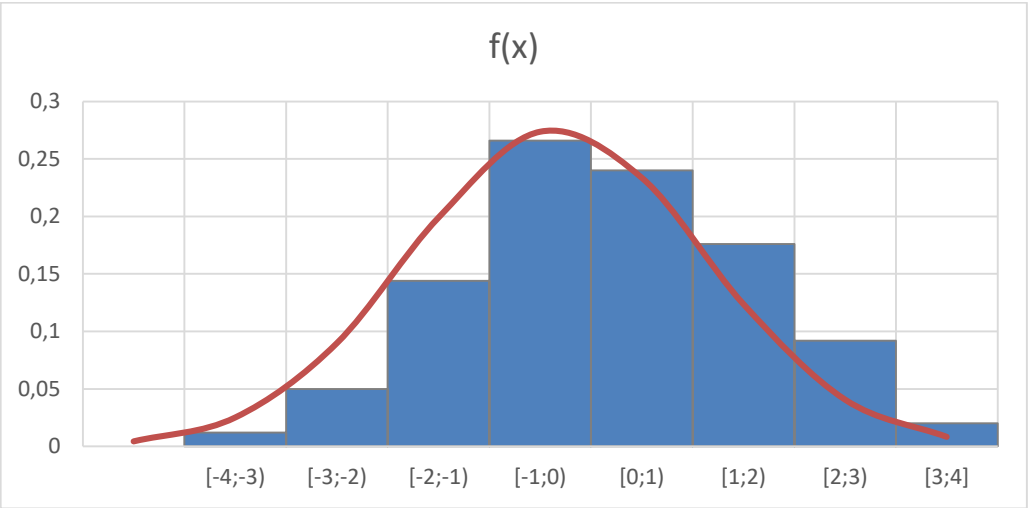
$$\sigma = \sqrt{D(x)} = \sqrt{\sum_{i=1}^{k} (x_i - \bar{x})^2 \cdot w_i}$$

$\bar{x} = -3{,}5\cdot 0{,}012 - 2{,}5\cdot 0{,}05 - 1{,}5\cdot 0{,}144 - 0{,}5\cdot 0{,}266 + 0{,}5\cdot 0{,}24 + 1{,}5\cdot 0{,}176 +$
$+ 2{,}5\cdot 0{,}092 + 3{,}5\cdot 0{,}02 = 0{,}168$

$D^*(X) = 2{,}098, \qquad \sigma^*(X) = 1{,}448$

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-a)^2}{2\sigma^2}} = \frac{1}{1{,}448 \cdot \sqrt{2\pi}} e^{-\frac{(x-0{,}168)^2}{2\cdot 1{,}448^2}}$$

x_i	–4	–3	–2	–1	0	1	2	3	4
$f(x)$	0,0044	0,0252	0,0898	0,1990	0,2736	0,2335	0,1238	0,0407	0,0083



$$A_s = 0{,}0138, \qquad E_k = -0{,}36$$

Рисунок 4.1 – Выравнивание статистического ряда