Статистические оценки параметров распределения. Ч.2.

1. Оценка математического ожидания
2. Оценка дисперсии
3. Доверительные интервалы для оценки математического ожидания нормального распределения
4. Ошибка выборки

1. Оценка математического ожидания

Генеральной средней $\bar{x}_{\text{г}}$ называют среднее арифметическое значений признака генеральной совокупности.

Рассматривая признак *X* генеральной совокупности как случайную величину, математическое ожидание признака равно генеральной средней:

$$M(X) = \bar{x}_{\text{г}} \tag{1.1}$$

Пусть из генеральной совокупности в результате независимых наблюдений извлечена повторная выборка объема *n* со значениями признака $x_1, x_2, \dots, x_n$, при этом генеральная средняя $\bar{x}_{\text{г}}$ неизвестна.

Оценкой генеральной средней и, следовательно, математического ожидания, является выборочная средняя $\bar{x}$.

Утверждение 1.1 Выборочная средняя $\bar{x}$ – несмещенная оценка математического ожидания.

Доказательство. Рассмотрим выборочную среднюю $\bar{x}$ как случайную величину $\bar{X}$, выборочные значения $x_1, x_2, \dots, x_n$ – как одинаково распределенные независимые случайные величины $X_1, X_2, \dots, X_n$.

Если несколько случайных величин имеют одинаковые распределения, то их числовые характеристики одинаковы

Обозначим математическое ожидание через a.

$$M(\bar{X}) = M\left(\frac{X_1 + X_2 + \cdots + X_n}{n}\right) = \frac{M(X_1) + M(X_2) + \cdots + M(X_n)}{n} = \frac{na}{n} = a,$$

ч. т. д.

Утверждение 1.2 Выборочная средняя $\bar{x}$ – состоятельная оценка математического ожидания.

Доказательство основано на теореме Чебышева, согласно которой при условии ограниченности дисперсий случайных величин $X_1, X_2, \ldots, X_n$ с увеличением *n* среднее арифметическое этих величин стремится по вероятности к среднему арифметическому их математических ожиданий:

$$\lim_{n\to\infty} P\left\{\left|\frac{X_1 + X_2 + \cdots + X_n}{n} - \frac{M(X_1) + M(X_2) + \cdots + M(X_n)}{n}\right| < \varepsilon\right\} = 1, \qquad \varepsilon > 0$$

Если $X_1, X_2, \ldots, X_n$ – попарно независимые случайные величины, имеющие одно и то же математическое ожидание a, то

$$\lim_{n\to\infty} P\{|\bar{X} - a| < \varepsilon\} = 1, \qquad \varepsilon > 0 \tag{1.2}$$

что соответствует определению состоятельности.

Если по нескольким выборкам достаточно большого объема из одной и той же генеральной совокупности будут найдены выборочные средние, то они будут приближенно равны между собой. В этом заключается свойство ***устойчивости выборочных средних****.*

Утверждение 1.3 Если случайная величина X распределена нормально с параметрами $N(a,\sigma)$, то оценка $\bar{X}$ математического ожидания имеет минимальную дисперсию, равную

$$D(\bar{X}) = \frac{\sigma^2}{n} \tag{1.3}$$

следовательно, $\bar{X}$ – *эффективная* оценка.

Доказательство:

$$D(\bar{X}) = D\left(\frac{X_1 + \cdots + X_n}{n}\right) = \frac{D(X_1) + \cdots + D(X_n)}{n^2} = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}$$

$$D(\bar{X}) \to 0 \text{ при } n \to \infty, \qquad \text{ч. т. д.}$$

2. Оценка дисперсии

Генеральной дисперсией $D_г$ называется среднее арифметическое значений квадратов отклонений значений признака генеральной совокупности от их среднего значения $\bar{x}_г$. Если все значения $x_1, x_2, \dots, x_n$ признака генеральной совокупности различны, то

$$D_г = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x}_г)^2 \qquad (2.1)$$

Генеральным средним квадратическим отклонением (стандартом) называют квадратный корень из генеральной дисперсии:

$$\sigma_г = \sqrt{D_г} \qquad (2.2)$$

Пусть из генеральной совокупности в результате независимых наблюдений извлечена повторная выборка объема *n* со значениями признака $x_1, x_2, \dots, x_n$. По данным выборки требуется оценить неизвестную генеральную дисперсию $D_г$.

Утверждение 2.1 Выборочная дисперсия $D_{\text{в}}$ – смещенная оценка генеральной.

Доказательство. Рассмотрим выборочные значения $x_1, x_2, \dots, x_n$ как одинаково распределенные независимые случайные величины $X_1, X_2, \dots, X_n$ с математическим ожиданием a и дисперсией σ^2. Если $x_1, x_2, \dots, x_n$ различны,

$$D_{\text{в}} = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2 \qquad (2.3)$$

Найдем математическое ожидание $D_{\text{в}}$, добавив в выражение $+a - a$:

$$M(D_{\text{в}}) = M\left(\frac{1}{n}\sum_{i=1}^{n}\left((X_i - a) - (\bar{X} - a)\right)^2\right) =$$

$$= M\left(\frac{1}{n}\sum_{i=1}^{n}(X_i - a)^2\right) - M\left(\frac{2}{n}\sum_{i=1}^{n}(X_i - a)\,(\bar{X} - a)\right) + M\left(\frac{1}{n}\sum_{i=1}^{n}(\bar{X} - a)^2\right).$$

$$1)\ M\left(\frac{1}{n}\sum_{i=1}^{n}(X_i-a)^2\right)=\frac{n\sigma^2}{n}=\sigma^2 \qquad (1)$$

$$2)\ M\left(\frac{2}{n}\sum_{i=1}^{n}(X_i-a)\,(\bar{X}-a)\right)=2M\left(\left(\frac{1}{n}\sum_{i=1}^{n}X_i-\frac{na}{n}\right)(\bar{X}-a)\right)=$$

$$=2M\big((\bar{X}-a)(\bar{X}-a)\big)=2M(\bar{X}-a)^2 \qquad (2)$$

$$3)\ M\left(\frac{1}{n}\sum_{i=1}^{n}(\bar{X}-a)^2\right)=M\left(\frac{n(\bar{X}-a)^2}{n}\right)=M(\bar{X}-a)^2 \qquad (3)$$

$$M(\bar{X}-a)^2=D(\bar{X})=\frac{\sigma^2}{n} \qquad (4)$$

Из $(1)-(4)$: $\qquad M(D_{\text{в}})=\sigma^2-\frac{2\sigma^2}{n}+\frac{\sigma^2}{n}=\frac{n-1}{n}\sigma^2\neq D_{\text{г}}$

следовательно, $D_{\text{в}}$ – смещенная оценка, ч. т. д.

Несмещенная оценка получается путем исправления выборочной дисперсии $D_{\text{в}}$ умножением на величину $\frac{n}{n-1}$:

$$s^2 = \frac{n}{n-1} D_{\text{в}}$$

Коэффициент $\frac{n}{n-1}$ называется поправкой Бесселя

Несмещенной оценкой генеральной дисперсии является *исправленная дисперсия*:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2 \qquad (2.4)$$

Несмещенной оценкой генерального СКО является *исправленное СКО*:

$$s = \sqrt{s^2} \qquad (2.5)$$

3. Доверительные интервалы для оценки математического ожидания нормального распределения

а) среднее квадратическое отклонение σ известно

Рассмотрим выборочную среднюю $\bar{x}$ как случайную величину $\bar{X}$, выборочные значения $x_1, x_2, \dots, x_n$ – как одинаково распределенные независимые случайные величины $X_1, X_2, \dots, X_n$.

Если случайная величина X распределена нормально, то и $\bar{X}$ распределена нормально с параметрами

$$M(\bar{X}) = a$$

$$\sigma(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

Пусть выполняется соотношение $P(|\bar{X} - a| < \delta) = \gamma$, где γ – заданная надежность.

$$P(|\bar{X} - a| < \delta) = P(-\delta < \bar{X} - a < \delta) = P(a - \delta < \bar{X} < a + \delta) =$$

$$= \Phi\left(\frac{a + \delta - a}{\sigma(\bar{X})}\right) - \Phi\left(\frac{a - \delta - a}{\sigma(\bar{X})}\right) = 2\Phi\left(\frac{\delta}{\sigma(\bar{X})}\right) = 2\Phi\left(\frac{\delta\sqrt{n}}{\sigma}\right) = 2\Phi(t)$$

$$t = \frac{\delta\sqrt{n}}{\sigma} \implies \delta = \frac{t\sigma}{\sqrt{n}}$$

Надежность оценки $\bar{x}$ параметра a определяется по формуле

$$P\left(\bar{x} - \frac{t\sigma}{\sqrt{n}} < a < \bar{x} + \frac{t\sigma}{\sqrt{n}}\right) = 2\Phi(t) = \gamma \qquad (3.1)$$

Доверительный интервал $(\bar{x} - t\sigma/\sqrt{n} < a < \bar{x} + t\sigma/\sqrt{n})$ с надежностью γ покрывает неизвестный параметр a. Точность оценки равна

$$\delta = \frac{t\sigma}{\sqrt{n}}$$

Число t определяется, исходя из равенства $2\Phi(t) = \gamma$, или $\Phi(t) = \gamma/2$.

Пример 3.1 Выборка из большой партии электроламп содержит 100 ламп. Средняя продолжительность горения лампы выборки оказалась равной 1000 ч. Найти с надежностью 0,95 доверительный интервал для средней продолжительности горения лампы всей партии, если известно, что среднее квадратическое отклонение продолжительности горения лампы равно 40 ч. Предполагается, что продолжительность горения ламп распределена нормально.

Решение Формализация условий задачи:

$$\bar{x} = 1000, \qquad \sigma = 40, \qquad n = 100, \qquad \gamma = 0{,}95$$

Среднее квадратическое отклонение дано, поэтому воспользуемся формулой (3.1). Для надежности $\gamma = 0{,}95$ определим t: $t = 1{,}96$.

Точность оценки

$$\delta = \frac{t\sigma}{\sqrt{n}} = \frac{1{,}96 \cdot 40}{\sqrt{100}} \approx 7{,}84$$

$$\bar{x} - \delta \approx 1000 - 7{,}84 = 992{,}16, \qquad \bar{x} + \delta \approx 1000 + 7{,}84 = 1007{,}84$$

Ответ: $992{,}16 < a < 1007{,}84$

б) среднее квадратическое отклонение σ неизвестно

По данным выборки можно построить случайную величину (ее возможные значения обозначены через t), которая имеет распределение Стьюдента с $k = n - 1$ степенями свободы:

$$T = \frac{\bar{x} - a}{s/\sqrt{n}}$$

$\bar{x}$ – выборочная средняя, n – объем выборки, s – «исправленное» среднее квадратическое отклонение:

$$s = \sqrt{\sum_{i=1}^{n} \frac{(x_i - \bar{x})^2}{n-1}} \tag{3.2}$$

$$P\left(\bar{x} - \frac{t_\gamma s}{\sqrt{n}} < a < \bar{x} + \frac{t_\gamma s}{\sqrt{n}}\right) = \gamma \tag{3.3}$$

Значения $t_\gamma = t(\gamma, n)$ табулированы.

Пример 3.2 Из генеральной совокупности извлечена выборка объема $n = 10$. Найти интервальную оценку математического ожидания a нормально распределенного признака генеральной совокупности с надежностью 0,95.

x_i	-2	1	2	3	4	5
n_i	2	1	2	2	2	1

4. Ошибка выборки

Величину средней ошибки простой случайной выборки при достаточно большом объеме выборки *n* можно определить по формуле:

для повторной выборки

$$\mu = \sqrt{\frac{\sigma^2}{n}}$$

для бесповторной выборки

$$\mu = \sqrt{\frac{\sigma^2}{n}\left(1 - \frac{n}{N}\right)}$$

$1 - n/N$ – доля единиц генеральной совокупности, не попавших в выборку.

Так как эта доля всегда меньше 1, то ошибка при бесповторном отборе при прочих равных условиях всегда меньше, чем при повторном. Если объем выборки мал по сравнении с объемом генеральной совокупности, выражением (1-n/N) при вычислении средней ошибки выборки можно пренебречь

Академик А.М. Ляпунов доказал, что вероятность появления случайной ошибки выборки при достаточно большом ее объеме подчиняется нормальному закону распределения и определяется по формуле

$$F(t) = \frac{1}{\sqrt{2\pi}} \int_{-t}^{t} e^{-\frac{z^2}{2}} dz = \frac{2}{\sqrt{2\pi}} \int_{0}^{t} e^{-\frac{z^2}{2}} dz = 2\Phi(t)$$

t – коэффициент доверия (кратности ошибки), указывающий, во сколько раз предельная ошибка выборки δ превышает среднюю ошибку μ:

$$\delta = t\mu$$

$F(t) = 2\Phi(t)$ – вероятность того, что предельная ошибка выборки превосходит среднюю ошибку в *t* раз:

t	1	1,96	2	2,58	3
F(*t*)	0,683	0,95	0,954	0,99	0,997

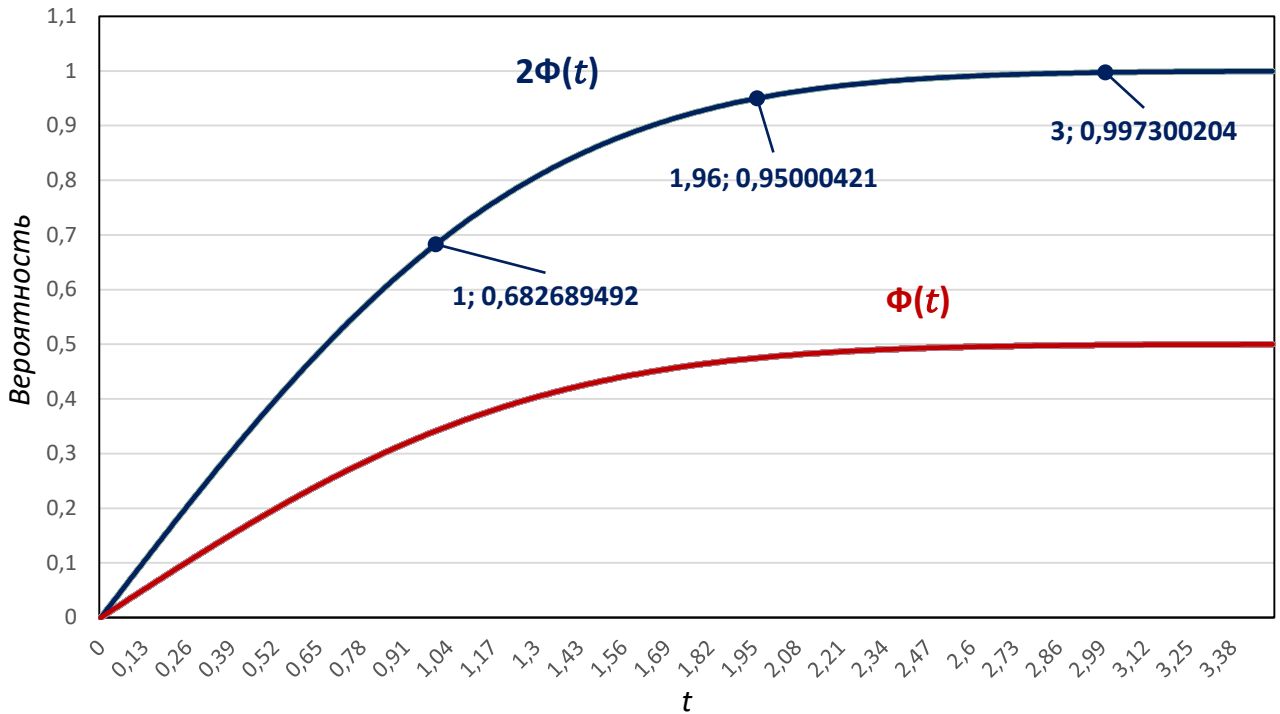


Рисунок 4.1 – Функция Лапласа